

ÔN VẤN ĐÁP BẢO VỆ ĐỒ ÁN — SỔ TAY CÁ NHÂN

Đào Sỹ Duy Minh

Project Manager & AI/ML Engineer · MSSV 23122041

Dự án **StoryLens** — Nền tảng AI dịch & hỏi–đáp Manga theo ngữ cảnh

Trình bày slide 1–5 · phụ trách Q&A: Quản lý dự án, AI/ML, chất lượng dịch, bản quyền

Môn học CSC10011 – Công nghệ phần mềm cho hệ thống Trí tuệ Nhân tạo

GVHD GS.TS Nguyễn Văn Vũ, ThS. Trương Phước Lộc, ThS. Ngô Ngọc Đăng Khoa

Nhóm Nhóm 1 – StoryLens · Ngày báo cáo 10/07/2026

Vai trò Q&A PM (LN03) · Fine-tune OCR + Prompt dịch (LN07) · Bản quyền/Đạo đức (LN12)

Contents

1	Chốt trong 30 giây: “Minh đã làm gì?”	2
2	Phần Minh thuyết trình (slide 1–5) — kể như một câu chuyện	2
3	Khối Quản lý dự án (LN03) — Minh dễ bị hỏi nhất	2
4	Khối AI/ML của Minh (LN07) — OCR + prompt dịch	4
5	Các câu Q&A Minh được phân công (từ phụ lục kịch bản)	5
6	Bẫy mâu thuẫn tài liệu (câu “bắt lỗi”)	6
7	Đạo đức AI & bản quyền (LN12) — vùng của Minh	7
8	15 câu bẫy khó nhất — luyện phản xạ nhanh	7
9	Phụ lục — Số liệu & điểm yếu phải thủ sẵn	8

1. Chốt trong 30 giây: “Minh đã làm gì?”

Nếu hội đồng hỏi thẳng: bạn đóng góp cụ thể gì trong dự án?

Trả lời. Em giữ **hai vai**: điều phối dự án và trực tiếp làm hai mắt xích AI quyết định chất lượng bản dịch.

- **Quản lý (PM):** chọn quy trình **RUP rút gọn + Scrum** (sprint 2 tuần, 4 pha Inception → Elaboration → Construction → Transition); lập & duy trì **Product/Sprint Backlog, WBS 31 task (135 story point), Gantt, Staff allocation, Risk register $RE = P \times L$, RTM, Burndown, Scrum log**; ước lượng bằng **Planning Poker + Story Points**; và bắt buộc mọi **Pull Request phải được review + CI xanh** mới merge vào main.
- **AI/ML (code thật):** **fine-tune manga-ocr** cho manga tiếng Nhật (**CER 6,1%**, độ chính xác ký tự 93,9%); **prompt engineering** cho **Gemini 2.5 Flash** dịch **theo cả trang** để giữ ngữ cảnh, xưng hô; và tối ưu quota API (caching, batch, xoay vòng key).
- **Task cụ thể trong WBS:** T1.2 (setup repo/board), **T2.1 fine-tune OCR trên Kaggle T4 (8 điểm)**, T4.1 (embedding pipeline / vector store), T5.3 (fix bug), T5.4 (tối ưu quota RPD), T6.5 (final deploy & smoke test).

Câu nói mạnh: “Em vừa giữ nhịp dự án, vừa chịu trách nhiệm trực tiếp cho hai bước AI quyết định chất lượng: đọc chữ (OCR) và dịch có ngữ cảnh (prompt LLM).”

2. Phần Minh thuyết trình (slide 1--5) --- kể như một câu chuyện

Slide 3 --- Vấn đề: vì sao thị trường cần StoryLens? [Cốt lõi]

Trả lời. Cộng đồng đọc manga Việt (chủ yếu **15–28 tuổi**) rất lớn nhưng gặp **ba rào cản**:

- **Fan-sub** ra chậm, chất lượng không đều, nhiều bộ bỏ dở vì thiếu nhân lực.
- Công cụ tự động (**Google Lens**) dịch **từng câu, mất ngữ cảnh** — không giữ xưng hô/mạch truyện; DeepL/ChatGPT phải thao tác thủ công từng ảnh.
- Người đọc **không có cách hỏi ngay** về nội dung truyện.

Gói gọn: thị trường **thiếu một nền tảng dịch manga tự động vừa hiểu ngữ cảnh, vừa hỏi–đáp thông minh**.

Slide 4--5 --- Định vị & khác biệt (product position statement) [Cốt lõi]

Trả lời. Tuyên ngôn định vị (thuộc lòng): “Cho người đọc manga Việt **15–28 tuổi** muốn đọc truyện Nhật chưa có bản dịch chính thức, StoryLens cho phép **tải trang lên, tự động dịch sang tiếng Việt có ngữ cảnh, và hỏi AI bất cứ điều gì về nội dung**.”

- **Bốn giá trị cốt lõi:** (1) dịch giữ ngữ cảnh cả trang; (2) đọc overlay bật/tắt so sánh bản gốc; (3) hỏi–đáp **RAG có nguồn trích**; (4) hệ sinh thái cộng đồng (thư viện/share/forum).
- **Ma trận 4 tiêu chí:** dịch tự động · hiểu ngữ cảnh cả trang · RAG hỏi–đáp · overlay. Google Lens/DeepL/ChatGPT/fan-sub mỗi cái chỉ đạt 1–2 tiêu chí — **chỉ StoryLens đủ cả bốn**.

3. Khối Quản lý dự án (LN03) --- Minh dễ bị hỏi nhất

Vì sao chọn Agile/Scrum mà không dùng Waterfall? [Cốt lõi]

Trả lời. Dự án **bất định công nghệ cao** (pipeline AI). Waterfall bắt chót toàn bộ yêu cầu/kiến trúc từ đầu; nếu đến tuần 10 mới phát hiện OCR sai hoặc pipeline quá chậm thì sửa kiến trúc cực đắt, dễ sập tiến độ. Scrum cho phép **lập & tăng dần**: ngay từ Sprint 2 đã có pipeline AI thô chạy được để thử tích hợp → giảm rủi ro sớm, luôn có *shippable increment* cuối mỗi sprint.

Vì sao KHÔNG dùng COCOMO để ước lượng nỗ lực? [Cốt lõi]

Trả lời. COCOMO cần ước lượng **KLOC** (nghìn dòng code) từ đầu — với dự án AI/RAG, số dòng code **không phản ánh độ khó** (10 dòng prompt Gemini khó hơn hàng trăm dòng HTML). Nhóm dùng **Planning Poker + Story Points**, đánh giá theo *độ phức tạp* $\times$ *độ bất định (rủi ro)* $\times$ *nỗ lực*. Mốc chuẩn: tính năng **Auth = 2 điểm**; **Pipeline AI = 8 điểm**. Các tính năng khác so với mốc để gán điểm.

Velocity của nhóm là bao nhiêu? Tổng effort?

Trả lời. Trả lời đúng số thật trong file, **KHÔNG** nói “20”:

- Tổng backlog **135 story point / 31 task**.
- **Velocity trung bình $\approx 22\text{--}23$ điểm/sprint** (Burndown thật: 23 / 24 / 23 / 26 / 22 / 17 qua 6 sprint; trung bình 22,5).

Mốc	Điểm hoàn thành	Còn lại (actual)	%
End S1	23	112	17%
End S2	24	88	35%
End S3	23	65	52%
End S4	26	39	71%
End S5	22	17	87%
End S6	17	0	100%

Bấy: nếu nói cứng “20 điểm” rồi hội đồng mở sheet Burndown thấy 22,5 là lệch $\rightarrow$ mất uy tín số liệu.

Là PM, bạn theo dõi tiến độ & kiểm soát chất lượng thế nào? [Cốt lõi]

Trả lời. Bốn cơ chế:

- **Kanban** (To Do $\rightarrow$ In Progress $\rightarrow$ Reviewing $\rightarrow$ Done), thẻ chia nhỏ ≤ 8 giờ.
- **Burndown chart** theo sprint (còn lại vs lý tưởng) để phát hiện chậm sớm.
- **Weekly Scrum** 3 câu hỏi (tuần qua làm gì / đang vướng gì / tuần tới làm gì) — có **Scrum log 12 tuần** trong file kế hoạch.
- **Code review chéo:** không ai push thẳng main; mọi PR ≥ 1 reviewer + CI xanh mới merge.

Cho xem bằng chứng quản lý dự án thật (không phải nói miệng)? [Cốt lõi]

Trả lời. Mở docs/management/StoryLens_Project_Plan.xlsx (10 sheet):

- Sheet WBS: 31 task T1.1–T6.5, người phụ trách, output, điểm, trạng thái.
- Sheet **Risk Register**: RE = Probability $\times$ Loss số hoá theo bảng LN03, có rank.
- Sheet Gantt (task $\times$ 12 tuần + mốc Build), Staff Allocation (6 người $\times$ 12 tuần), RTM, Burndown, Scrum log.

Rủi ro lớn nhất của dự án và cách ứng phó? (Risk register) [Cốt lõi]

Trả lời. RE = Probability $\times$ Loss (thang LN03). Top rủi ro:

ID	Rủi ro	RE	Rank	Ứng phó
R2	Quota/chi phí LLM API vượt budget	5625	1	Cache; key-pool 4 key (~2000 RPD); fallback free tier
R5	Dữ liệu manga vướng bản quyền	5625	2	Dùng dataset public (Manga109-s); nội dung do user đăng
R1	OCR accuracy < 95% (CER cao)	3750	3	Thêm dữ liệu; fine-tune manga-ocr
R4	ChromaDB không scale	3750	4	Đã chuyển sang pgvector

Bạn là PM nhưng slide nói "flat team không phân cấp" --- có mâu thuẫn?

Trả lời. Không. **Flat team** nói về việc *quyết định kỹ thuật được thảo luận tập thể*, không có cấp trên áp đặt giải pháp. Vai trò PM của em là **điều phối tiến độ, quản lý backlog, quản trị rủi ro, và giữ công chất lượng (PR review + CI)** — là trách nhiệm quy trình, không phải quyền lực ra lệnh kỹ thuật. Hai điều này không xung đột.

4. Khối AI/ML của Minh (LN07) --- OCR + prompt dịch

Nêu 8 bước ML Workflow nhóm áp dụng. [Cột 10]

Trả lời. Requirements → Data collection & preparation → Feature engineering → Model training → **Model evaluation** → Model deployment → Operating & monitoring → Maintenance (retrain từ ca lỗi khó: chữ SFX, viết tay).

(BẦY LỚN NHẤT) Bạn fine-tune manga-ocr thế nào? Chứng minh nó tốt hơn model gốc?

Trả lời. Có ablation hợp lệ + artifact xác minh — số liệu thật trong model_evaluation.docx (PA4):

- **Cách làm:** base kha-white/manga-ocr-base (VisionEncoderDecoderModel), **fine-tune full** trên **Manga109-s**. Dataset OCR **123.208 cặp** (crop bong bóng + nhãn chữ Nhật), chia **split-by-title**, **seed = 42** (chống rò rỉ) → Train 97.602 / Val 11.476 / **Test 14.130**.
- **Cấu hình:** 8 epochs, AdamW, lr = 3e-5, cosine schedule, warmup 5%, label-smoothing = 0.1, weight_decay = 0.01, fp16; chọn best theo **CER val nhỏ nhất**, early-stop patience 3; train trên **Kaggle Tesla T4**.
- **Bảng chứng fine-tune hiệu quả (ablation 2 vòng, cùng dataset/test-split/base):**

Phiên bản	Char-Acc	CER
PA2 (fine-tune sơ bộ, ít epoch)	87,3%	12,7%
PA3 (fine-tune hoàn chỉnh)	93,9%	6,1%

- **CER giảm 12,7% → 6,1% ($\approx$ giảm hơn 50% lỗi).** Khớp chính xác 4 chữ số với artifact thật ai_module/models/manga_ocr/weights/metadata.json (test_cer = 0.061090) → chứng minh là output huấn luyện thật, không phải số gõ tay.

Demo sống n=1 cho thấy fine-tune đọc SAI chữ đầu --- vậy nó tệ hơn base?

Trả lời. Đó là 1 mẫu (n=1) trên ảnh minh họa AI-generated ngoài phân phối Manga109-s — chỉ là smoke-test định tính, **không dùng để kết luận**. Bảng chứng chuẩn là **test split 14.130 mẫu**: CER 12,7% → 6,1%. Kết quả n=1 chỉ phản ánh: mô hình được tối ưu cho **phong cách line-art Manga109-s**, chưa tổng quát hoá hoàn hảo sang mọi phong cách vẽ — đúng như giới hạn đã ghi nhận trong SAD.

Giải thích công thức & ý nghĩa CER, mAP@0.5, IoU, Precision. [Cốt lõi]**Trả lời.**

- **CER** (đánh giá OCR — phần của Minh): $CER = \frac{S + D + I}{N}$ (S thay thế sai, D xóa/bỏ sót, I chèn thừa, N tổng ký tự chuẩn). **6,1%** = trong 100 chữ chỉ sai ~6.
- **IoU** = diện tích giao / diện tích hợp giữa khung dự đoán & khung thật; ngưỡng ≥ 0.5 tính là đúng.
- **Precision** = $\frac{TP}{TP + FP} = 97,3\%$ — rất ít vẽ nhầm khung dịch vào chi tiết phong cảnh.
- **mAP@0.5** = trung bình Average Precision (diện tích dưới PR-curve) tại $IoU \geq 0.5 = 95,3\%$; Recall 93,8%; $mAP@0.5:0.95 = 84,4\%$.
- **Dữ liệu đánh giá:** Manga109-s, test **956 ảnh** / **>14.130 vùng chữ**, ngưỡng đặt 85% → đều vượt.

Vì sao chọn YOLOv8n (nano) chứ không model lớn hơn cho chính xác hơn? [Cốt lõi]

Trả lời. YOLOv8n chỉ ~**3M tham số**, chạy được **CPU-only** trên HuggingFace Spaces free tier (không GPU), độ trễ detection ~**0,13 giây/ảnh**; vẫn đạt **mAP@0.5 = 95,3%** > **ngưỡng 85%**. Chọn nano là cân bằng chính xác/chi phí hợp lý cho hạ tầng miễn phí — dùng model lớn hơn sẽ tràn RAM và chậm mà lợi ích biên không đáng kể.

Prompt dịch của bạn cụ thể là gì? “Context injection” nghĩa là gì? [Cốt lõi]

Trả lời. Module dịch (task T3.2: GlossaryManager + LLMClient gọi Gemini) đưa **cả trang + glossary xung hô** vào prompt thay vì dịch từng bong bóng rời. Nhờ “**context injection**” này, Gemini giữ **nhất quán xung hô, mạch truyện, sắc thái** trên toàn trang. Kèm **xoay vòng nhiều API key** chống hết quota và **fallback M2M100/NLLB** khi Gemini lỗi.

OCR sai thì Gemini tự sửa --- nhưng nếu OCR sai nặng, Gemini bịa (hallucinate) thì sao?

Trả lời. Đúng, đây là rủi ro “Artificial Stupidity”. Nhóm giảm bằng ba lớp: (1) dịch **cả trang có ngữ cảnh** nên Gemini có nhiều tín hiệu để suy đoán đúng; (2) **cảnh báo khi độ tin cậy OCR thấp** ngay trên reader; (3) **Studio QC** cho dịch giả sửa tay từng bong bóng, lưu lịch sử hiệu đính. **AI không có tiếng nói cuối cùng — con người mới quyết định** (human-in-the-loop).

CER 6,1% đo trên Manga109-s. User upload manga phong cách khác thì CER thật bao nhiêu? [Trung thực]

Trả lời. Trung thực: 6,1% là **in-distribution** (đúng phân phối huấn luyện). Out-of-distribution **chưa đo bằng số** (mới có 1 mẫu định tính) — đây là giới hạn đã ghi rõ trong báo cáo. Nhóm bù bằng **Gemini self-correction** và **Studio QC**. Hướng phát triển: chạy đánh giá trên vài chục mẫu chữ Nhật ngoài phân phối để có ước lượng CER thô.

5. Các câu Q&A Minh được phân công (từ phụ lục kịch bản)**Làm sao đảm bảo chất lượng bản dịch? (Minh / Phú Hòa) [Cốt lõi]**

Trả lời. Gemini dịch **theo cả trang** nên giữ ngữ cảnh, xung hô; cộng **human-in-the-loop**: Studio QC cho duyệt/sửa từng bong bóng và cơ chế phản hồi tốt/xấu (endpoint `/v1/pages/{id}/feedback`) để cải thiện dần. Ngưỡng chấp nhận theo SAD: tỉ lệ $\square \geq 80\%$.

Vấn đề bản quyền manga thì sao? (Minh / Quý) [Trung thực]

Trả lời. StoryLens là **công cụ hỗ trợ đọc/dịch**, không phải nơi phát tán. Ba lớp: (1) mô hình huấn luyện trên **dataset học thuật Manga109-s** (giấy phép nghiên cứu); (2) nội dung người dùng upload mặc định **Private**, có **điều khoản sử dụng + công cụ kiểm duyệt admin**; (3) roadmap có **quy trình DMCA take-down**. Đã ghi nhận là **Risk R5** trong risk register.

Điểm khác biệt lớn nhất so với ChatGPT / Google Lens? (Minh) [Cốt lõi]

Trả lời. Ba-trong-một **chuyên biệt** mà công cụ chung không có: (1) dịch **cả trang giữ ngữ cảnh**; (2) **render overlay đúng bong bóng** (binary-search chọn cỡ chữ vừa khít); (3) **RAG hỏi–đáp giới hạn theo đúng thư viện riêng của từng người dùng, có nguồn trích**. ChatGPT/Lens chỉ làm một phần, không render vào bong bóng, không hỏi–đáp trên đúng nội dung truyện của bạn.

Vì sao tài liệu PA ghi ChromaDB / all-MiniLM / GPT-4 mà sản phẩm là pgvector / Gemini? (Phú Hòa / Minh)

Trả lời. Đây là **sự tiến hoá qua các vòng lặp RUP** — điểm mạnh về kỹ năng ra quyết định, không phải lỗi:

- Kế hoạch ban đầu: ChromaDB + embedding all-MiniLM + GPT-4.
- Khi hiện thực: hợp nhất về **pgvector ngay trong Supabase** (bớt một dịch vụ, đỡ vận hành — **Risk R4** ghi rõ “ChromaDB không scale → đã đổi pgvector”); chọn **Gemini** để đồng bộ (vừa dịch, vừa embedding **768 chiều**, vừa RAG, xoay vòng key rẹ).
- Sản phẩm cuối phản ánh quyết định kỹ thuật tốt hơn bản kế hoạch.

Đóng góp từng thành viên / cách làm việc nhóm? (Minh) [Cốt lõi]

Trả lời. Flat team **6 người**, RUP rút gọn + Scrum, sprint 2 tuần, weekly scrum, mọi PR review:

- **Minh (23122041)** — PM & AI/ML: quản lý tiến độ, fine-tune OCR, prompt dịch.
- **Hà Dương (23122002)** — AI/ML (OCR): dataset, hỗ trợ fine-tune, đánh giá accuracy.
- **Kiệt (23122039)** — Backend: FastAPI, DB schema, tích hợp pipeline.
- **Phú Hòa (23122030)** — AI/ML (RAG): Gemini, pgvector, pipeline hỏi–đáp.
- **Nguyễn (23122044)** — Frontend: Next.js Upload/Reader/Q&A.
- **Phú Quý (23122048)** — QA & BA: SDP/Vision/Use case, test case, UAT.

6. Bẫy mâu thuẫn tài liệu (câu “bắt lỗi”)**WBS ghi task ChromaDB/FAISS (T2.3, T4.1) nhưng sản phẩm dùng pgvector --- giải thích?**

Trả lời. WBS là **kế hoạch ở thời điểm lập**; kiến trúc tiến hoá qua các sprint là chuyện bình thường trong RUP/Agile. Bằng chứng nhóm *chủ động* ra quyết định nằm ngay trong **Risk register R4** (“ChromaDB không scale → chuyển pgvector”). Không phải sai lệch tài liệu mà là **quản trị thay đổi có ghi vết**.

Vì sao chọn embedding 768 chiều? Có phải tùy tiện? [Cốt lõi]

Trả lời. 768 chiều là kích thước vector chuẩn của gemini-embedding-001. Chọn nó để **đồng bộ toàn hệ Gemini** (một nhà cung cấp cho cả dịch, embedding, RAG → đơn giản vận hành, chung cơ chế xoay vòng key), và pgvector index thẳng vector 768 chiều với cosine similarity.

7. Đạo đức AI & bản quyền (LN12) --- vùng của Minh

Train trên Manga109-s và cho user dịch truyện có bản quyền --- có vi phạm? [Trung thực]

Trả lời. Tách hai chuyện: (1) **huấn luyện** dùng **Manga109-s** — dataset học thuật có giấy phép nghiên cứu, hợp lệ cho mục đích nghiên cứu/giáo dục; (2) **nội dung người dùng upload** do người dùng tự chịu trách nhiệm, mặc định **Private**, có điều khoản + kiểm duyệt admin + roadmap DMCA. Đây là **Risk R5** đã nhận diện và có chiến lược ứng phó.

AI Bias trong hệ thống là gì? [Trung thực]

Trả lời. YOLOv8 & OCR huấn luyện chủ yếu trên **Manga109-s (manga Nhật)** → **distribution bias**: giỏi với phong cách Nhật (bong bóng tròn, line-art), **kém hơn với manhwa Hàn / manhwa Trung**. Nhóm **ghi nhận rõ giới hạn** trong tài liệu; hướng khắc phục = bổ sung dataset đa dạng để giảm bias. Theo LN12: “Principles alone cannot guarantee ethical AI” — nên nhóm **đo và công bố giới hạn**, không chỉ hứa “cố gắng công bằng”.

Hệ thống có theo dõi chất lượng mô hình AI sau deploy không (MLOps)? [Trung thực]

Trả lời. Có đủ **giám sát hạ tầng** (Sentry bắt lỗi, OpenTelemetry theo dõi latency, Admin health dashboard, /health/deep). **Model monitoring** (theo dõi drift mAP/CER theo thời gian) **chưa có** — vì đang ở giai đoạn MVP, model chạy tĩnh (update thủ công). Hướng phát triển: tích hợp **W&B / MLflow** để theo dõi drift và trigger retrain tự động.

8. 15 câu bẫy khó nhất --- luyện phản xạ nhanh

1. **Fine-tune OCR thế nào?** → base manga-ocr-base, fine-tune full Manga109-s (123k cặp, split-by-title seed 42), 8 epochs AdamW lr=3e-5 cosine, T4 Kaggle. CER 12,7% → 6,1%, xác minh bằng metadata.json.
2. **Demo n=1 fine-tune đọc sai — tệ hơn base?** → n=1 ảnh ngoài phân phối, smoke-test; chuẩn là test split 14.130 mẫu.
3. **CER thực khi manga khác phong cách?** → Trung thực: chỉ đo in-distribution; OOD chưa đo; bù bằng Gemini + Studio QC.
4. **OCR sai → Gemini bịa?** → Rủi ro có thật; giảm bằng dịch cả trang + cảnh báo confidence + human-in-the-loop.
5. **Prompt dịch & context injection?** → GlossaryManager+LLMClient, đưa cả trang + glossary xung hô vào prompt; fallback M2M100/NLLB.
6. **Vì sao YOLOv8n nano?** → 3M tham số, CPU-only free tier, 0,13s/ảnh, vẫn mAP 95,3% > 85%.
7. **Velocity? Tổng effort?** → ~22–23 SP/sprint, tổng 135 SP / 31 task. (KHÔNG nói “20”).
8. **Vì sao không COCOMO?** → Cần KLOC, không đo được độ khó AI; dùng Planning Poker + Story Points.
9. **PM mà flat team — mâu thuẫn?** → Flat = quyết định kỹ thuật tập thể; PM lo tiến độ/backlog/rủi ro/PR gate.
10. **Bảng chứng PM thật?** → StoryLens_Project_Plan.xlsx: WBS, Gantt, Risk RE=P×L, RTM, Burn-down, Scrum log.
11. **ChromaDB trong WBS vs pgvector?** → Tiến hoá RUP; Risk R4 ghi rõ “đã đổi pgvector”.
12. **GPT-4/all-MiniLM vs Gemini?** → Cùng lý do tiến hoá; Gemini đồng bộ dịch+embedding 768+RAG, xoay vòng key rẻ.

13. **Bản quyền?** → Train Manga109-s (license nghiên cứu); user content Private + kiểm duyệt + DMCA roadmap; Risk R5.
14. **Khác ChatGPT/Lens?** → 3-trong-1: dịch cả trang + overlay render + RAG scoped có nguồn trích.
15. **Model monitoring sau deploy?** → Có infra monitoring (Sentry/OTel/health); model drift chưa có, roadmap W&B/MLflow.

9. Phụ lục --- Số liệu & điểm yếu phải thử sẵn

Số liệu & mẹo phải thuộc

Số phải bật ra ngay khi bị hỏi:

- OCR: **CER 6,1%** (Char-Acc 93,9%, exact-match 67,5%); ablation **12,7% → 6,1%**.
- Detection: **mAP@0.5 = 95,3%**, mAP@0.5:0.95 = 84,4%, Precision 97,3%, Recall 93,8% (ngưỡng 85%).
- Dataset: Manga109-s, OCR **123.208 cặp** (80/10/10, seed 42); detection test **956 ảnh / 14.130 vùng chữ**.
- PM: **135 SP / 31 task**, velocity ~**22–23 SP/sprint**, 6 sprint × 2 tuần, 3 mốc Build.
- Kiến trúc: **3 dịch vụ** (Vercel / Render 512MB / HF Spaces ~4GB), embedding **768 chiều**, CI **5 job**.
- Rủi ro top: R2 quota & R5 bản quyền (RE = 5625).

Điểm yếu phải thừa nhận trung thực (kèm định hướng) --- đừng để reviewer bắt trước

- **YOLO thiếu artifact gốc** (chỉ có best.pt, không có results.csv/PR-curve) → số mAP dựa vào SAD PA3; hướng khắc phục: lưu results.csv khi train lại.
- **CER out-of-distribution chưa đo** (mới n=1 định tính) → hướng: đánh giá vài chục mẫu OOD.
- **Không có Model Monitoring** (drift) → đang MVP, roadmap W&B/MLflow.
- **Defect log rỗng** (61/61 Pass, 0 defect) → nếu bị nghi “test cho có”, trích 1–2 bug thật từ git history.
- **Chưa có dữ liệu feedback dịch sống** (không truy cập Supabase production) → mô tả đúng cơ chế đã hiện thực, không suy diễn số.